



SAVFE (SAVE AND SAFE)

BRIAN ALEXANDER - 2702282351

CHRISTIAN GAVRIEL E.H - 2702266064

MICHAEL WIJAYA - 2702272911

TABLE OF CONTENT

1

BACKGROUND

2

IDEAS, GOAL, AND
IMPACT

3

DATASET
EXPLORATORY

4

FLOW UI AND MOCKUP
DESIGN

5

MODEL PROPOSAL

6

CONCLUSION

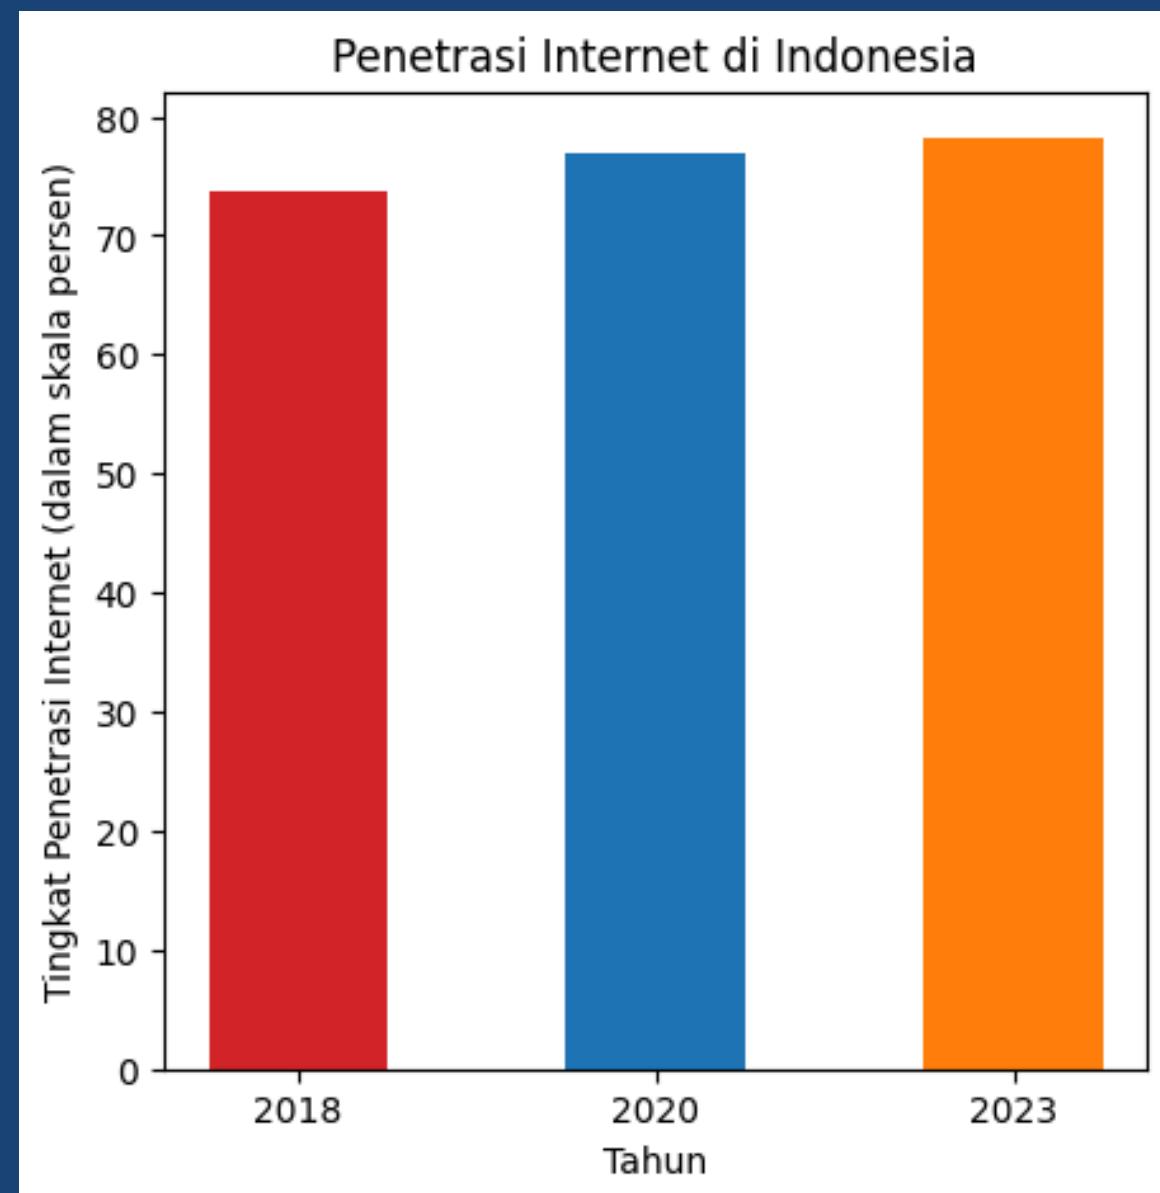
BACKGROUND

Di era Revolusi Industri 4.0 yang ditandai dengan perkembangan teknologi internet yang cepat ini. Keamanan data menjadi prioritas utama terutama untuk data negara yang pastinya memiliki banyak informasi sensitif terkait keamanan, ekonomi dan politik yang dimana sifat sifat dari data data tersebut adalah rahasia maka harus dijaga dengan ketat. Kebocoran data tidak hanya berdampak pada keamanan nasional tetapi juga dapat menimbulkan ancaman terhadap stabilitas negara, kepentingan publik, dan hubungan diplomatik dengan negara lain.

BACKGROUND

Dari Grafik Disamping dapat dilihat bahwa jumlah pengguna internet di Indonesia meningkat setiap tahunnya Terhitung sejak 2018 penetrasi internet Indonesia mencapai 64.8% , Pada tahun 2020 sebanyak 73.7% dan pada 2023 tingkat penetrasi di Indonesia meningkat menjadi 78.19%

Sumber : <https://apjii.or.id/berita/d/apjii-jumlah-pengguna-internet-indonesia-tembus-221-juta-orang#:~:text=Terhitung%20sejak%202018%2C%20penetrasi%20internet,sstandard%20error%200%2C43%25>



BACKGROUND

Data disamping menunjukkan serangan siber di indonesia selama semester pertama 2024 serangan siber di Indonesia mencapa 2.449.286.085 jumlah serangan ini meningkat cukup signifikan dari semester 1 tahun 2023 sebanyak 13.733.440 serangan kenaikannya meningkat sebanyak lebih dari 600%

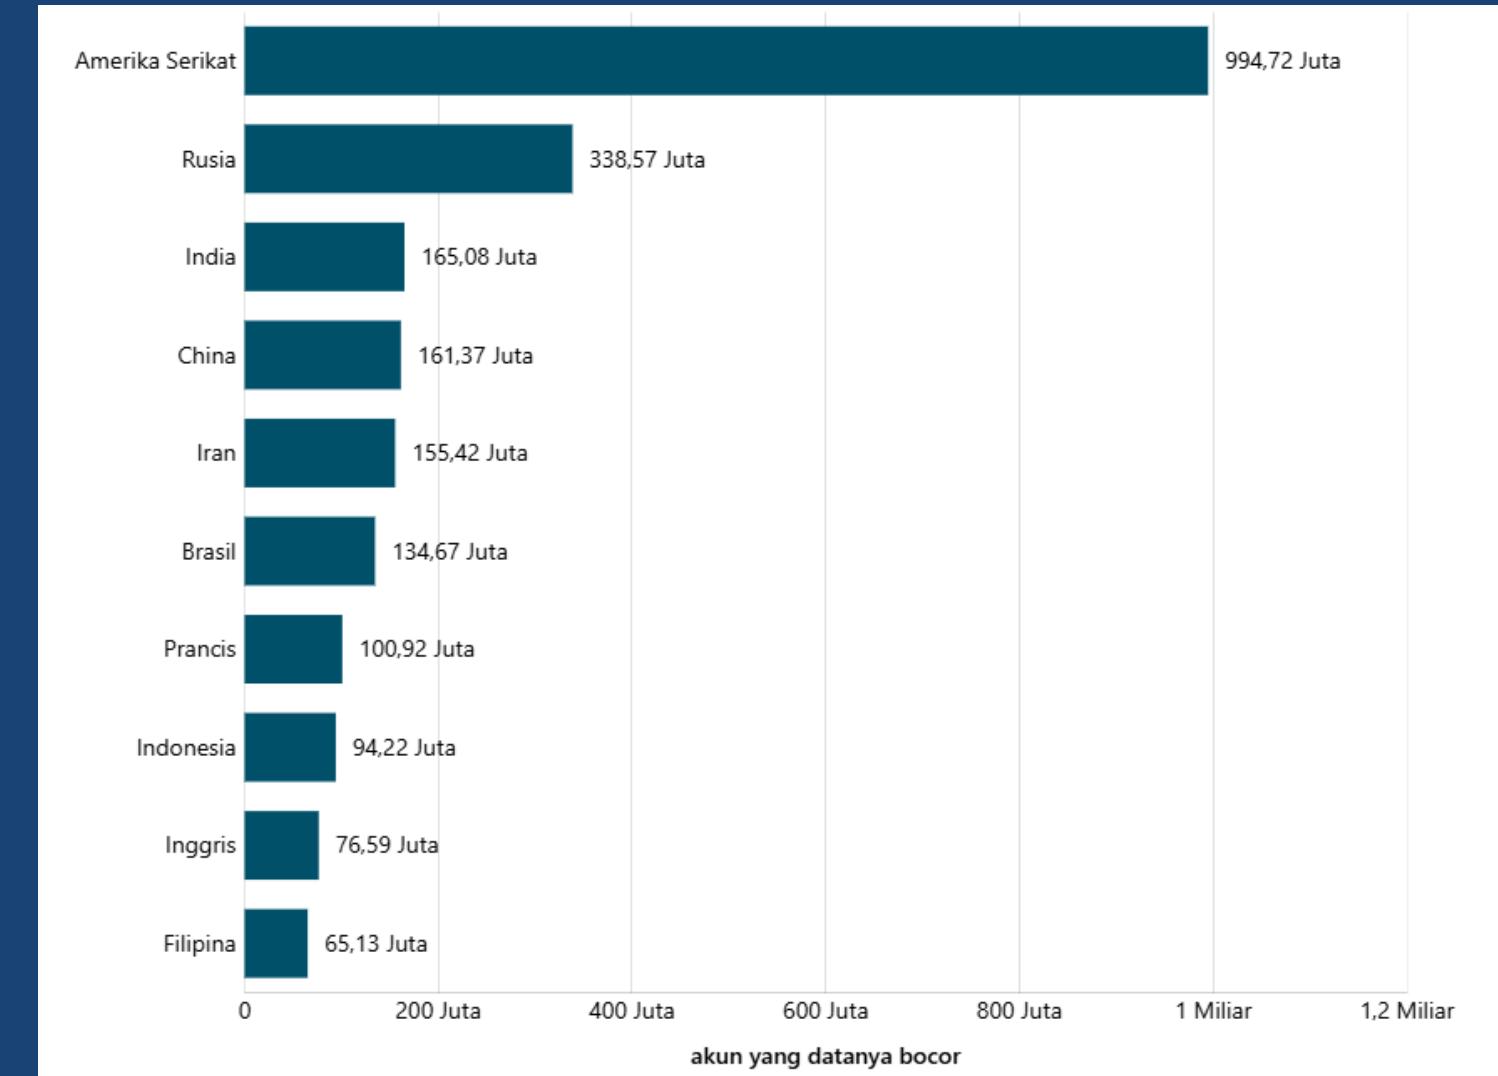
Sumber : <https://kumparan.com/kumparantech/serangan-siber-ke-ri-naik-6-kali-lipat-pada-h1-2024-majoritas-dari-dalam-negeri-23PnYQpafrf/full>



BACKGROUND

Data disamping menunjukkan 10 negara dengan tingkat kebocoran data terbesar tercatat (januari 2020 - januari 2024) dan indonesia menempati peringkat 8 dari 10 negara dengan banyaknya kebocoran data sebanyak 94.22 juta data yang bocor.

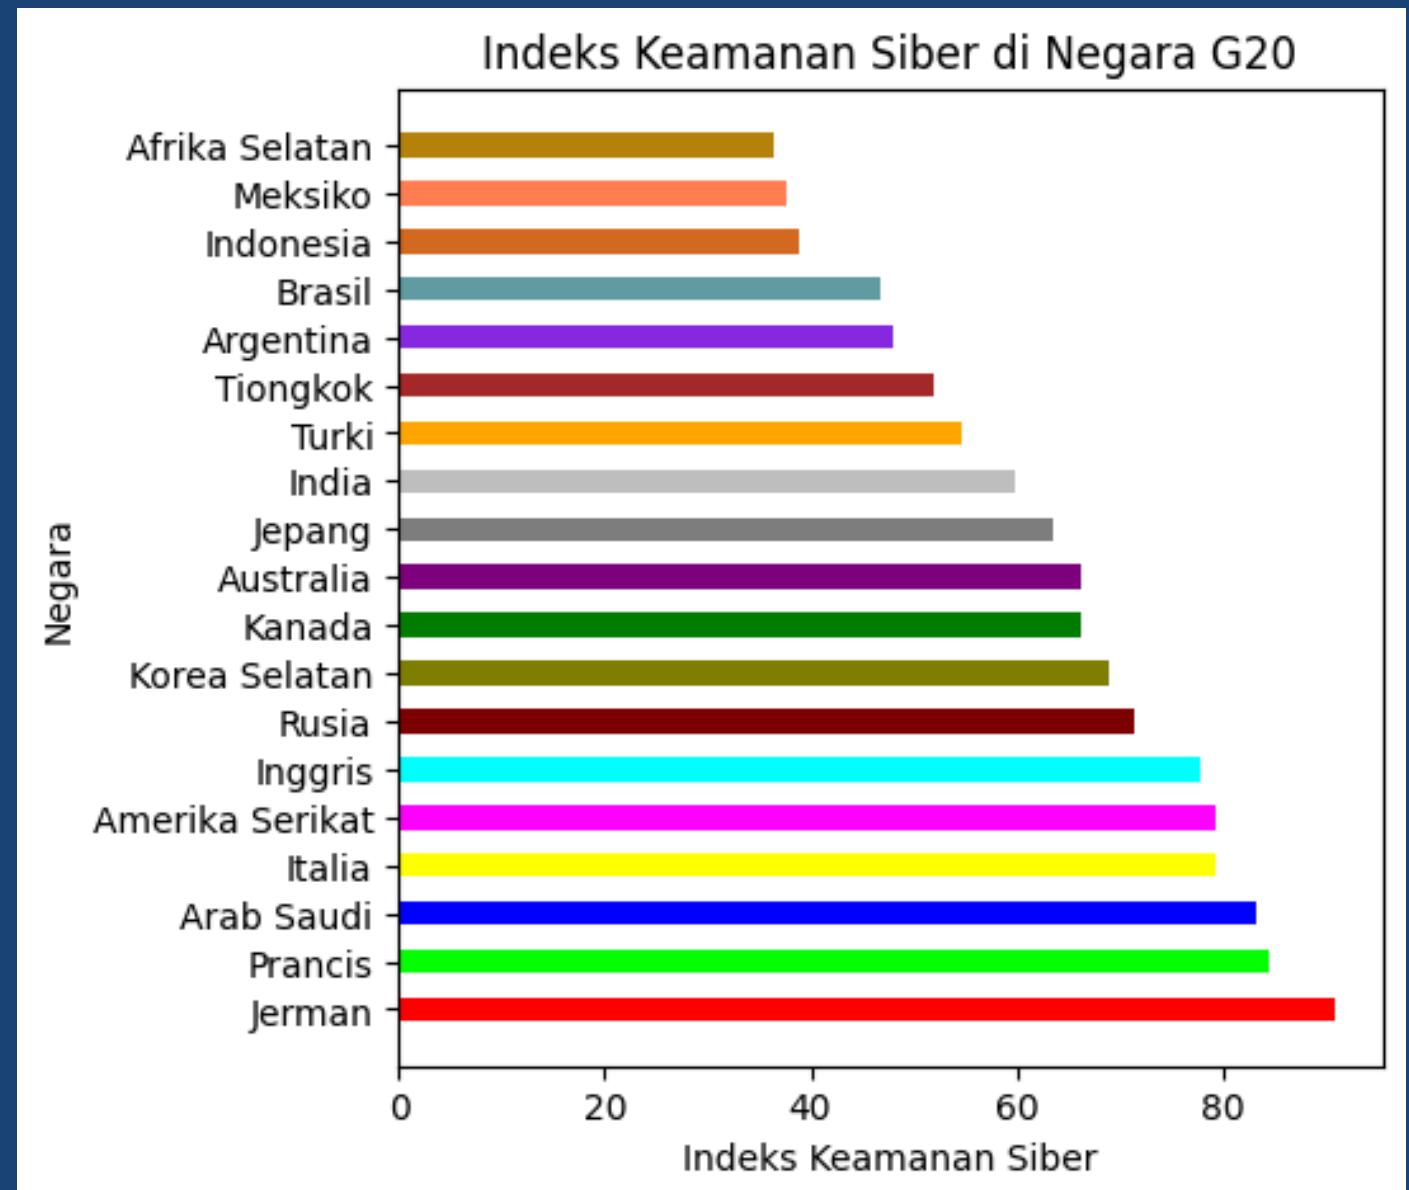
Sumber : <https://databoks.katadata.co.id/teknologi-telekomunikasi/statistik/cc5473708a4f8dc/indonesia-masuk-10-negara-dengan-kebocoran-data-terbesar>



BACKGROUND

Data disamping indeks keamanan siber di antara negara negara G20 dan dari data disamping dapat dilihat bahwa indonesia meraih peringkat ke-3 dengan Indeks Keamanan Siber Terendah di Antara Negara G20 sebesar 38.96

Sumber : <https://databoks.katadata.co.id/teknologi-telekomunikasi/statistik/40085035d61073f/indeks-keamanan-siber-indonesia-peringkat-ke-3-terendah-di-antara-negara-g20>



IDEA

Di sinilah SAVFE hadir untuk menyelesaikan permasalahan yang ada pada dunia keamanan siber Indonesia. SAVFE akan menggunakan teknologi bernama *face recognition* pada penggunanya sebelum dapat mengakses data. Jika pengguna tidak terdaftar maka otomatis tidak dapat mengakses data yang ada di SAVFE.



GOAL

Tujuan dari Pengembangan SAVFE adalah untuk mengamankan data-data penting dari perusahaan perusahaan besar maupun pemerintahan. Sehingga memininalisir terjadinya kebocoran data rahasia kepada publik.

IMPACT

- Peningkatan keamanan

Face recognition memungkinkan untuk mengurangi kemungkinan pihak yang tidak terverifikasi untuk mengakses data yang bersifat rahasia

- Kenyamanan pengguna

Karena menggunakan *face recognition* sehingga pengguna tidak perlu menginput password secara terus menerus setiap kali ingin mengakses data

- Penurunan Serangan Siber

Dengan menguatnya sistem keamanan siber membuat penjahat menjadi semakin sulit untuk membobol sistem keamanan tersebut maka tentu akan menurunkan angka kejahatan siber yang terjadi.

APLIKASI YANG DIPAKAI



Kami menggunakan HTML, CSS, dan JavaScript sebagai front end dan django sebagai backend pada aplikasi kami karena teknologi ini menyediakan struktur dasar, gaya, dan interaktivitas yang dibutuhkan untuk menciptakan antarmuka yang responsif, ramah pengguna, dan mudah diakses. HTML mendefinisikan konten dan tata letak, CSS memungkinkan desain yang menarik, JavaScript menambahkan fungsionalitas dinamis yang membuat aplikasi menjadi interaktif dan menarik serta MySQL untuk penyimpanan data user. Kombinasi ini memastikan pengembangan aplikasi berbasis web yang efisien, menarik secara visual, dan fungsional.

MOCKUP DESIGN

ACCESS GRANTED



**NAME : MICHAEL WIJAYA
AGE : 21
ROLE : STAFF**

ENTER

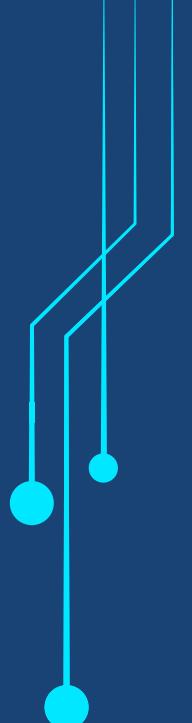
LINK UI DESIGN



DATASET



[LINK GOOGLE DRIVE DATASET](#)



INCEPTION MODULE

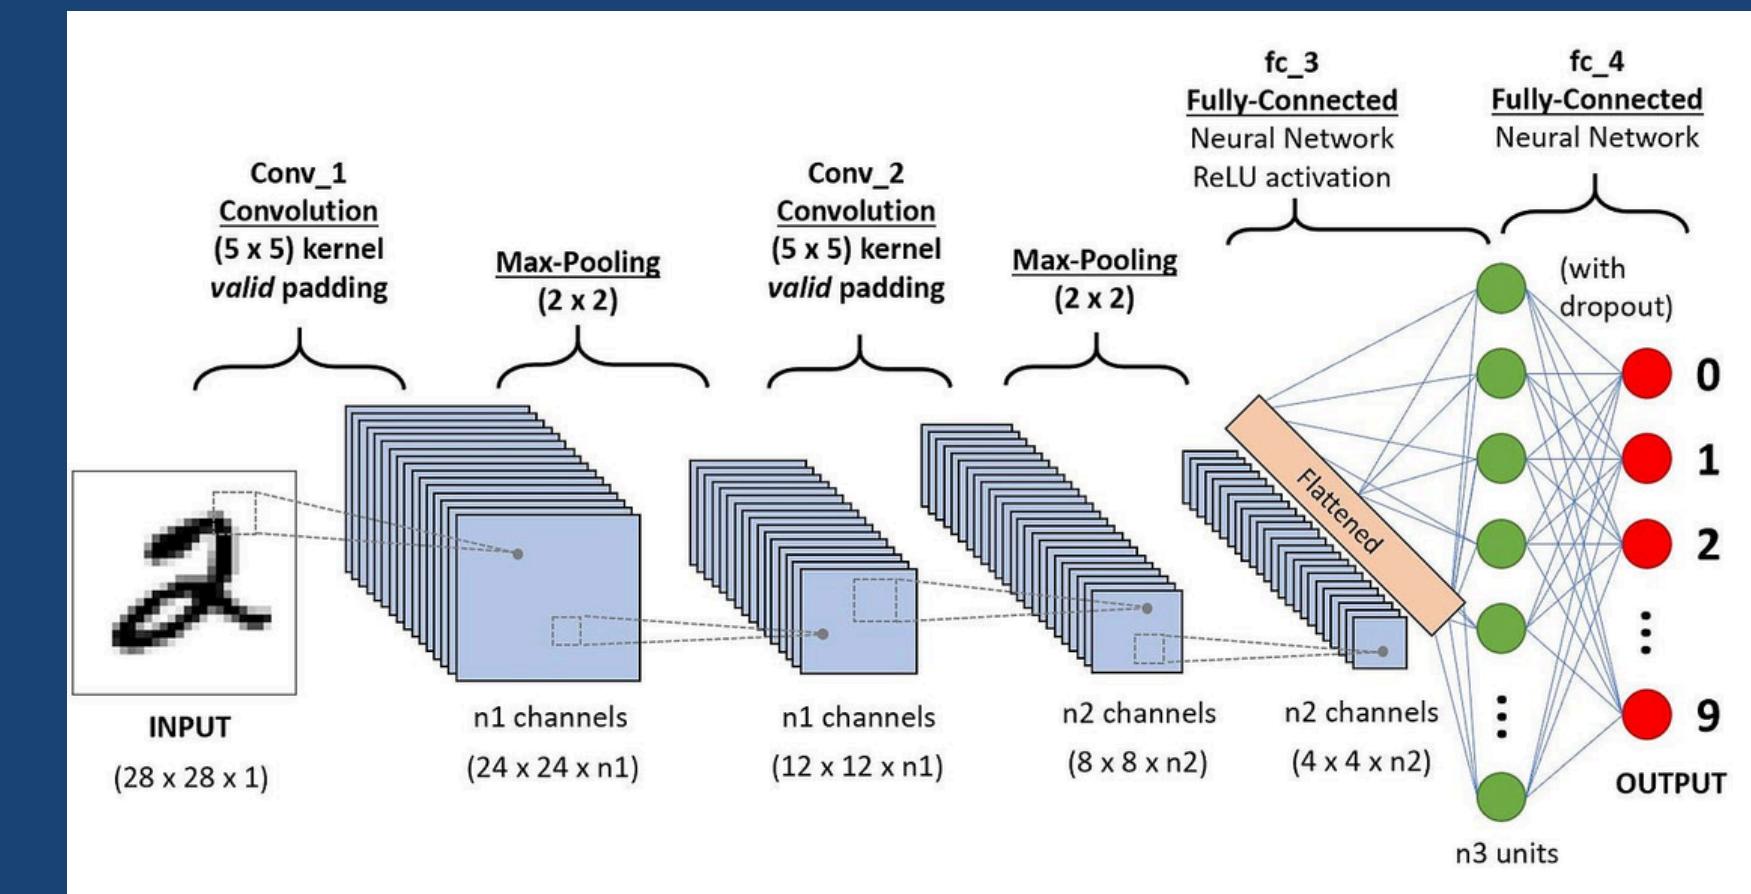
Inception module merupakan salah satu dari turunan *Convolutional Neural Network Architecture* (CNN) yang diperkenalkan oleh peneliti Google dalam paper yang berjudul “Going deeper with Convolutions” pada tahun 2014. *Architecture* ini atau dikenal dengan nama GoogLeNet memberikan peningkatan secara keefektifan komputing dan juga akurasi dengan menggabungkan berbagai filter dengan ukuran yang berbeda di dalam satu layer memungkinkan neural network dalam mempelajari beberapa filter sekaligus.



sumber: <https://deeppai.org/machine-learning-glossary-and-terms/inception-module>

WHAT IS CNN?

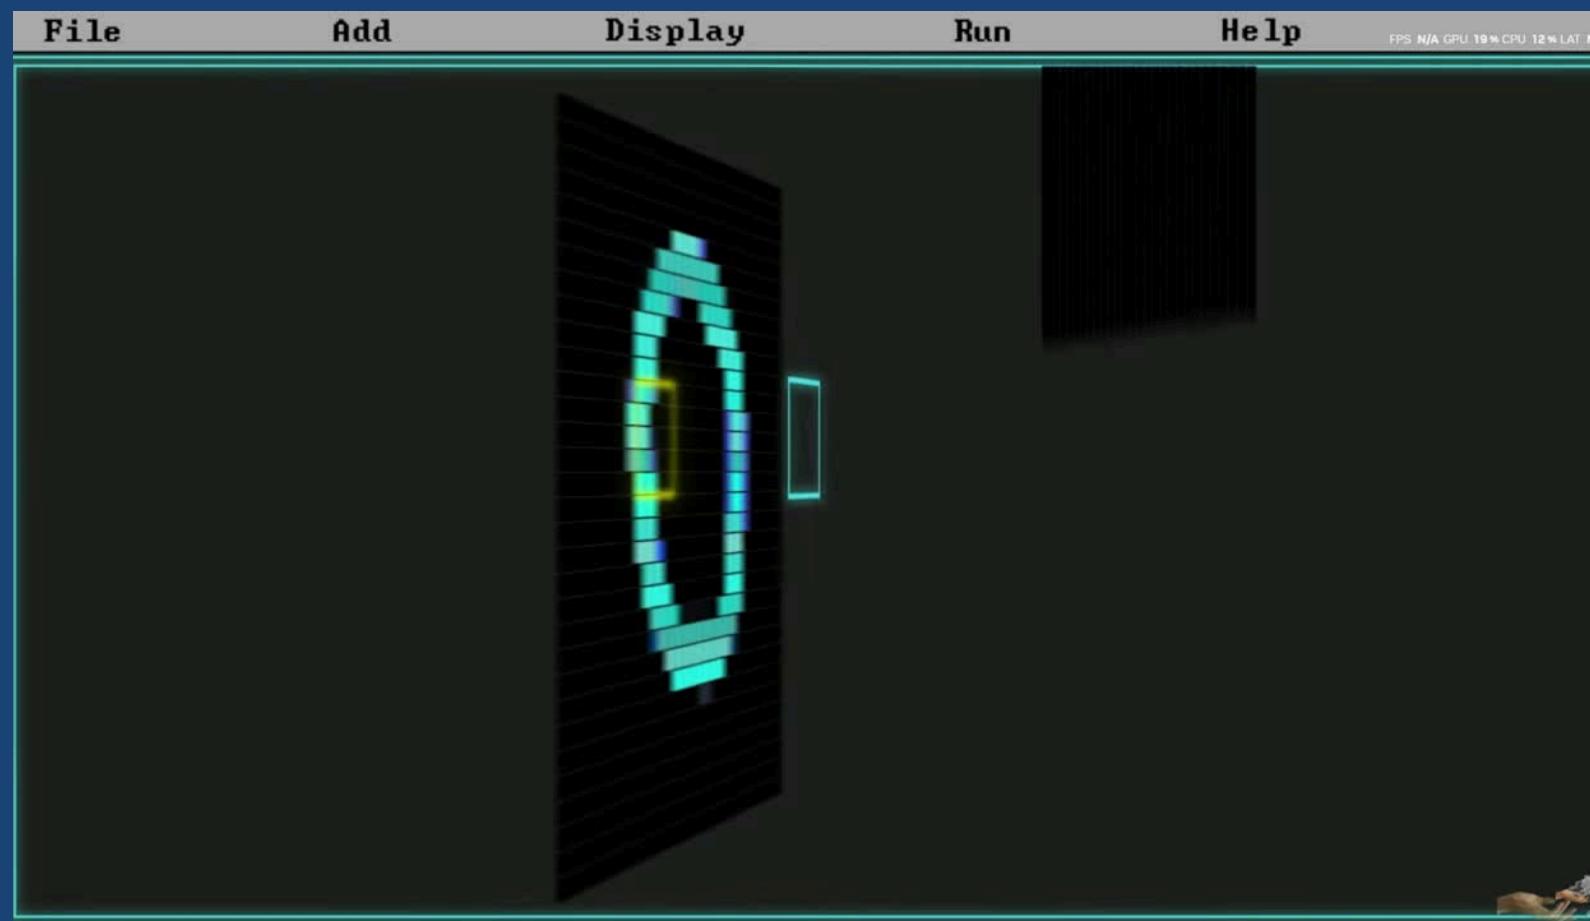
Secara singkat CNN adalah *Artificial Neural Network* yang didesain untuk memproses data yang berstruktur grid seperti gambar. Biasanya digunakan untuk pengenalan gambar, dan deteksi objek karena CNN mampu untuk menangkap dimensi spatial dari sebuah gambar.



CONVOLUTION

Sebuah gambar pasti terdiri dari banyak pixel yang menyusunnya dan setiap dari pixel tersebut juga tersusun dari matriks berisi angka-angka yang mengartikan kombinasi untuk menghasilkan warna tertentu. Nah, Proses convolution ini menggunakan kernel berukuran 1×1 , 3×3 , 5×5 yang dinamakan filter ini berisikan nilai-nilai random yang kemudian akan mengekstrak detail seperti warna, pola , dan teksture dari sebuah gambar. Jadi filter ini akan menjelajahi seluruh pixel dari sebuah gambar untuk menghasilkan beberapa output baru.

CONVOLUTION



sumber : <https://www.youtube.com/watch?v=pj9-rr1wDhM&t=201s>

CONVOLUTION

Perhitungan convolution untuk membentuk pixel baru menggunakan rumus:

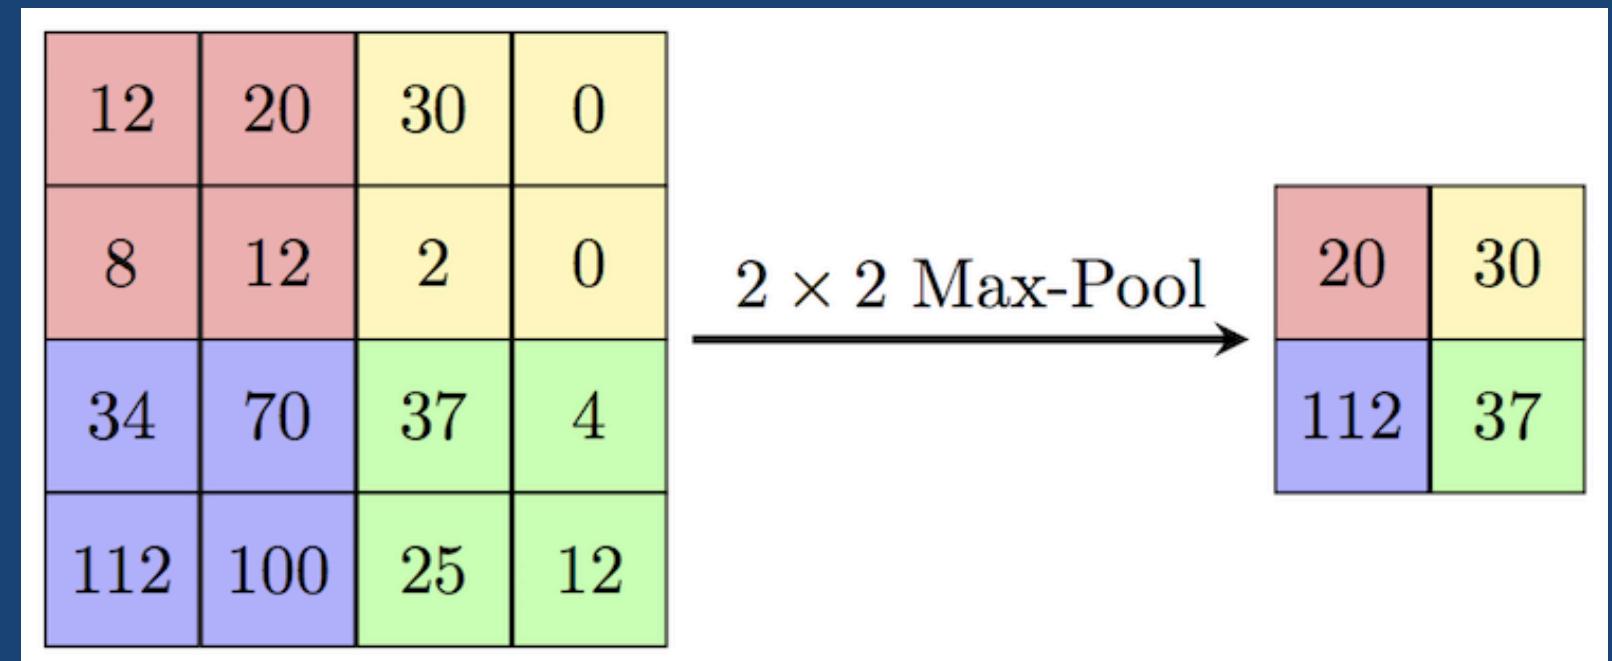
$$O(i, j) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} I(i + m, j + n) \cdot K(m, n)$$

Berikut adalah terjemahan penjelasan istilah dalam formula konvolusi:

- $O(i, j)$ adalah nilai keluaran pada posisi (i, j) dalam feature map (peta fitur) hasil konvolusi.
- $I(i + m, j + n)$ adalah nilai input dari gambar pada posisi $(i + m, j + n)$.
- $K(m, n)$ adalah nilai filter pada posisi (m, n) .
- M dan N adalah dimensi filter (sering kali 3×3 , 5×5 , dsb.).

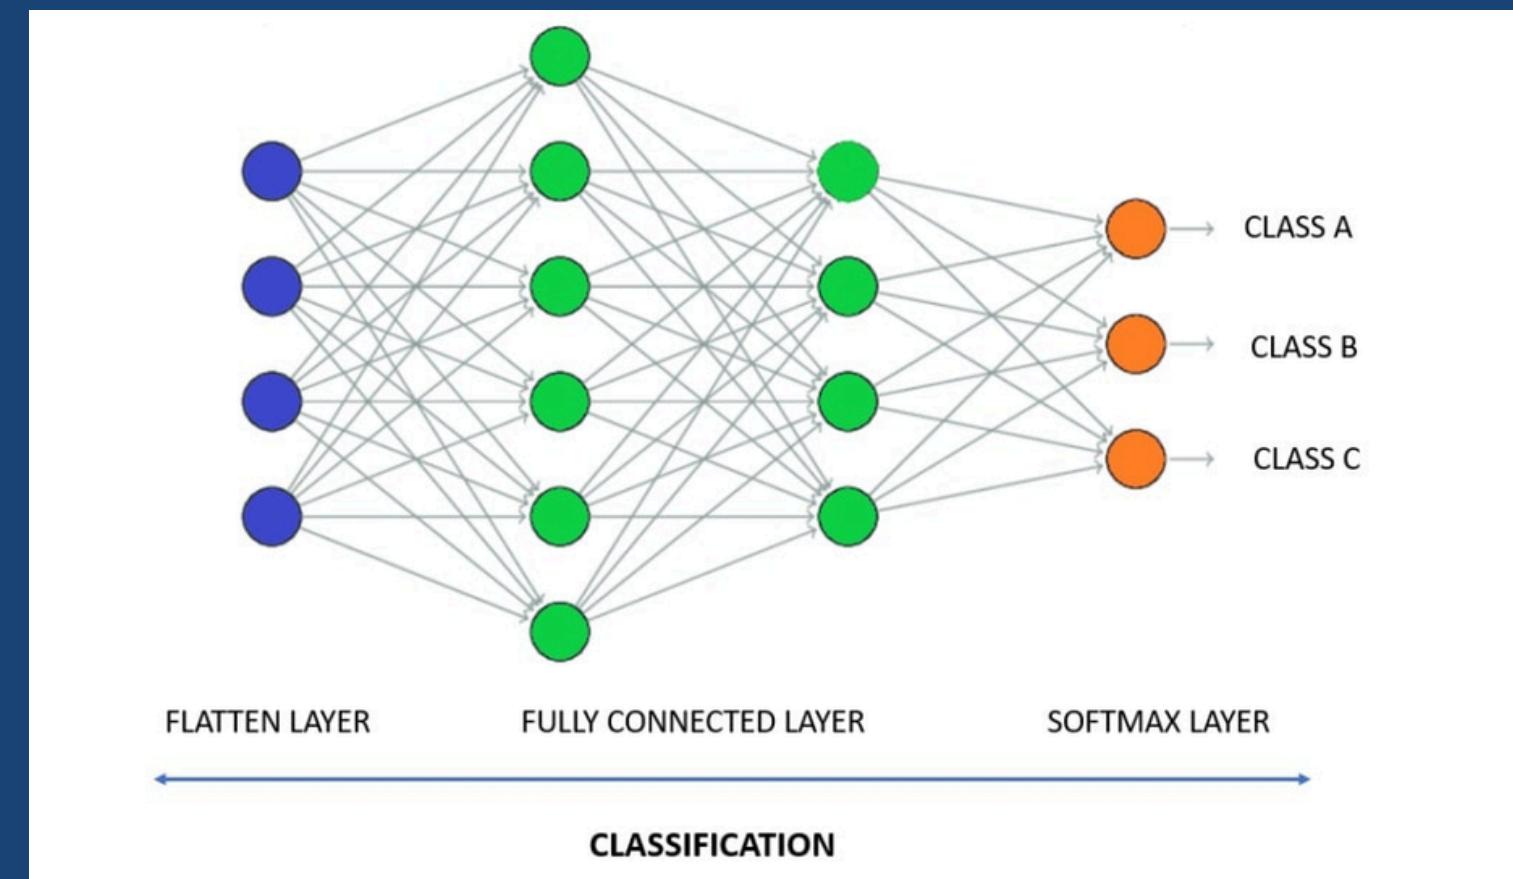
MAX POOLING

Pooling adalah proses untuk mengecilkan dimensi setelah melalui proses convolution metodenya ialah mengambil nilai terbesar/rata-rata dari grid kecil dari sebuah gambar yang kemudian menjadi pixel baru. Metode yang paling populer adalah max pooling dimana value yang diambil adalah value terbesar.



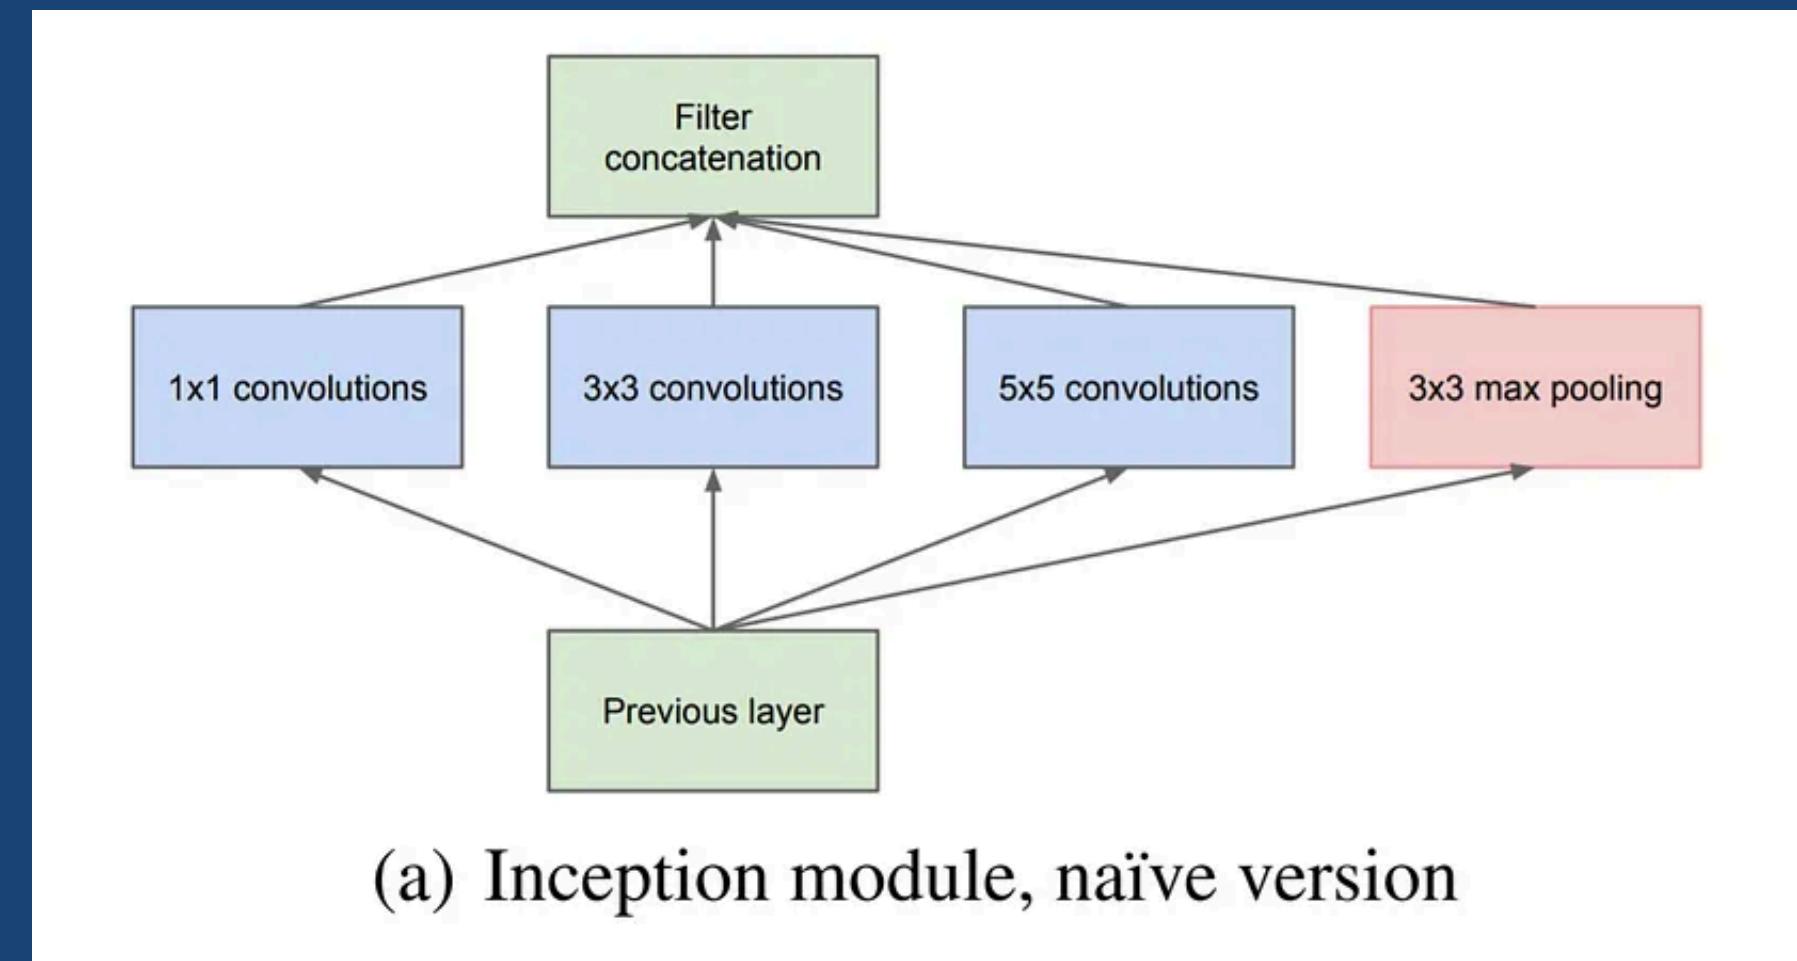
FULLY CONNECTED

Tahapan terakhir dalam CNN ialah fully connected. Dalam proses ini, semua fitur-fitur penting yang sudah diambil dari proses konvolusi akan digunakan dan mengambil keputusan akhir atau klasifikasi di layer ini.



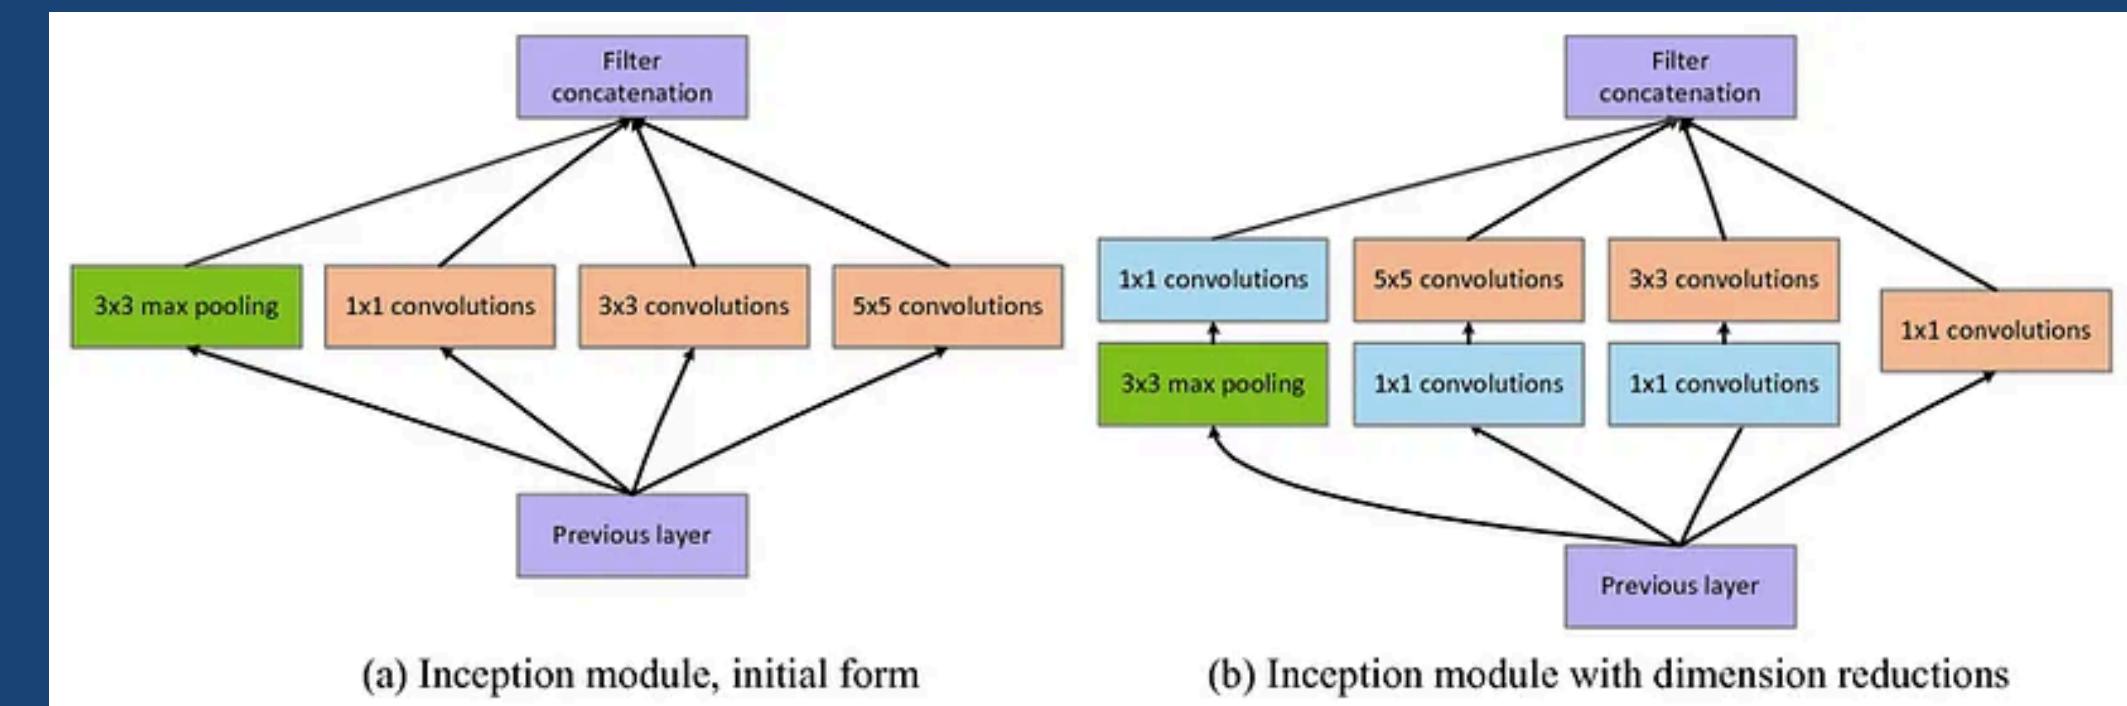
INCEPTION V1 (NAIVE)

Versi naive merupakan konsep inception pertama yang dikenalkan. Module ini menggunakan filtering 1x1, 3x3, 5x5 sekaligus dan 3x3 max pooling dalam mengekstraksi informasi dalam sebuah gambar yang kemudian di *concatenate* menjadi output baru.



INCEPTION V1 (DIMENTION REDUCTION)

Versi naive cukup memakan banyak dimensi karena menggunakan 3×3 dan 5×5 convolution, maka kita pecahkan mereka untuk mengurangi dimensi daripada convolution tersebut. Pada bagian pooling juga ditambahkan convolution 1×1 setelahnya. Lalu kenapa ditambahkan 1×1 terlebih dahulu??



INCEPTION V1(DIMENTION REDUCTION)

Anggap kita akan melakukan 3×3 convolution dengan 64 channel dan ingin menghasilkan 128 channel maka perhitungannya akan menjadi:

- $3 \times 3 \times 64 \times 128 = 73,728$ parameter

Sedangkan jika kita menggunakan 1×1 convolution terlebih dahulu untuk mengurangin 64 channel menjadi 32 channel akan mendapatkan hasil

- $1 \times 1 \times 64 \times 32 = 2,048$ parameter

kemudian baru kita gunakan 3×3 convolution akan menghasilkan

- $3 \times 3 \times 32 \times 128 = 36,864$ parameter

yang totalnya adalah

- $2,048 + 36,864 = 38,912$ parameter

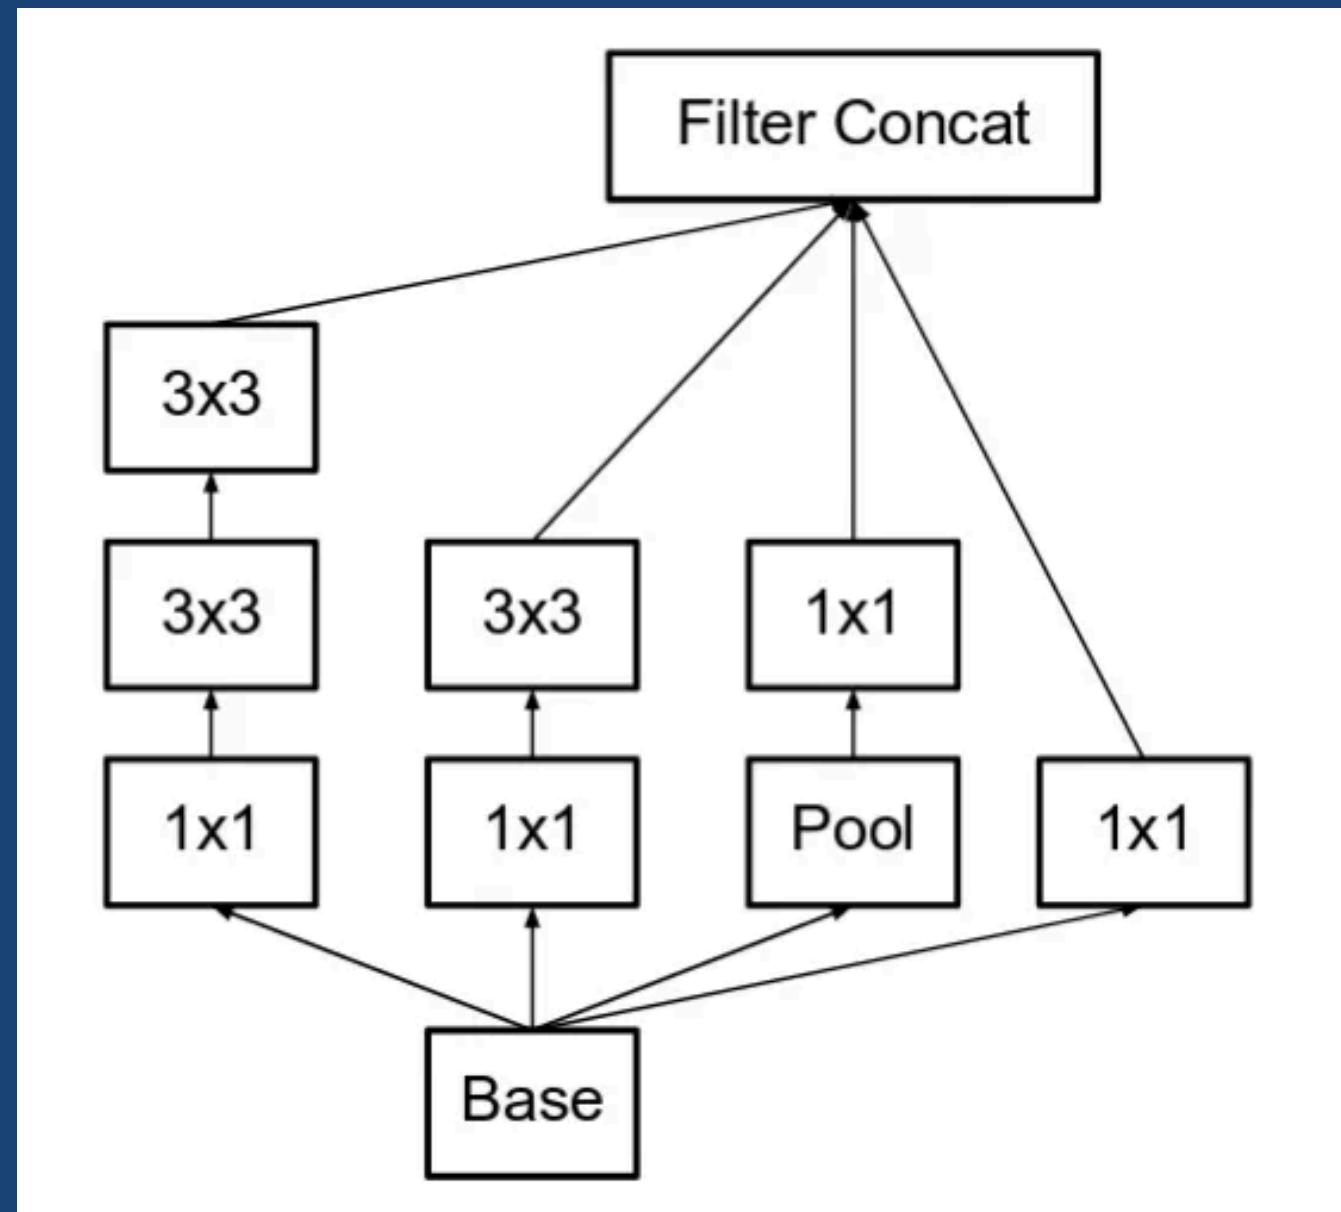
Perbandingan

- Tanpa konvolusi 1×1 : 73,728 parameter
- Dengan konvolusi 1×1 : 38,912 parameter

Kita telah mengurangi parameter sebanyak 47% yang mengartikan kita mengurangi beban komputasi karena mengurangi jumlah parameter yang dibutuhkan.

INCEPTION V2

Versi ini merupakan versi yang lebih efisien daripada v1. Karena mengenalkan *factorized convolution* dan *batch optimization*. *Factorized convolution* memecah 5×5 menjadi 2 3×3 convolution. *Batch normalization* menormalisasi output untuk mempercepat konvergensi model selama pelatihan.



BATCH NORMALIZATION

Input: Values of x over a mini-batch: $\mathcal{B} = \{x_1 \dots m\}$;
Parameters to be learned: γ, β

Output: $\{y_i = \text{BN}_{\gamma, \beta}(x_i)\}$

$$\mu_{\mathcal{B}} \leftarrow \frac{1}{m} \sum_{i=1}^m x_i \quad // \text{mini-batch mean}$$

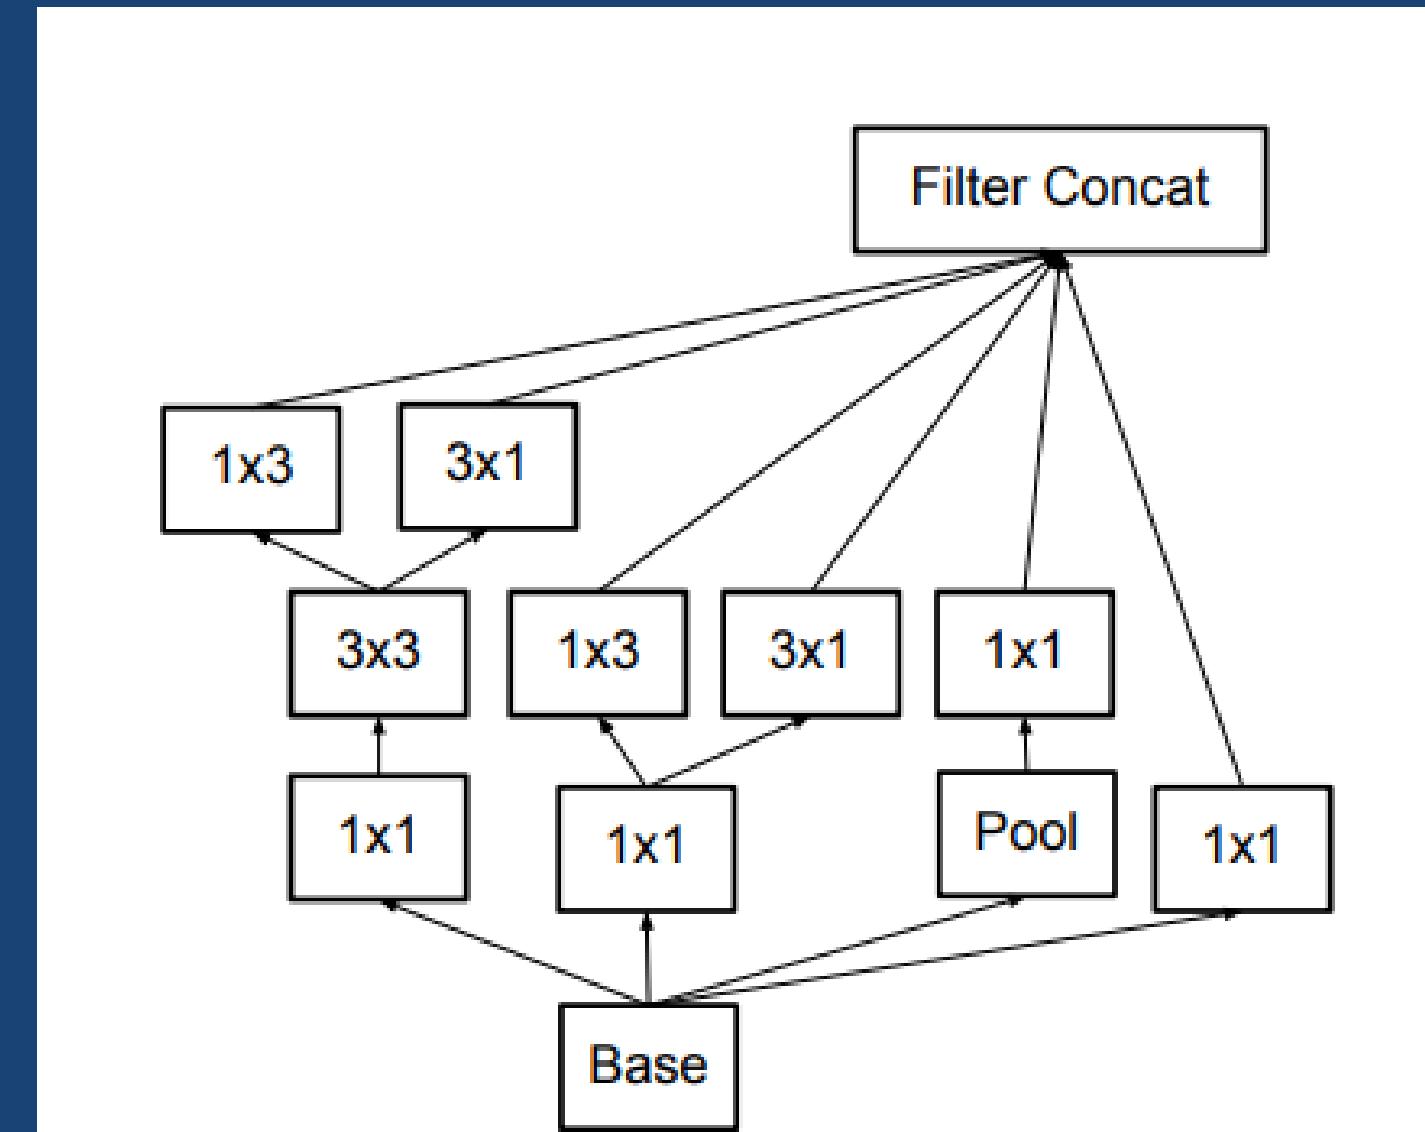
$$\sigma_{\mathcal{B}}^2 \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_{\mathcal{B}})^2 \quad // \text{mini-batch variance}$$

$$\hat{x}_i \leftarrow \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}} \quad // \text{normalize}$$

$$y_i \leftarrow \gamma \hat{x}_i + \beta \equiv \text{BN}_{\gamma, \beta}(x_i) \quad // \text{scale and shift}$$

INCEPTION V3

Versi ini mengenalkan *asymmetric convolution* untuk mengoptimalkan module-module sebelumnya. *Asymmetric convolution* adalah mengganti convolusi 3×3 dengan dua convolusi berturut-turut berukuran 3×1 dan 1×3 . Teknik ini lebih efisien dalam pengelolaan parameter sekaligus mempertahankan informasi penting.



KEUNGGULAN INCEPTION

- Efisiensi

Karena inception menggunakan beberapa filter sekaligus dalam 1 layernya, maka ini sangat menghemat computing resources dalam mengambil informasi dari gambar tanpa memperdalam networknya

- Meminimalisir overfitting

Dengan kombinasi filter multi-skala dan operasi pooling, Inception dapat belajar fitur yang lebih kaya tanpa mengandalkan pola spesifik pada skala tertentu. Arsitektur modular ini membantu jaringan dalam generalisasi yang lebih baik dan mengurangi risiko overfitting, terutama pada dataset yang terbatas.

- Kemampuan menangani Resolusi Berbeda

Karena menggunakan filter yang ber variasi, maka ini tentu membuat inception dirancang untuk menangani resolusi yang ber variasi juga.

KEUNGGULAN INCEPTION

- Fleksibilitas dalam Desain Arsitektur:

Karena modul ini dapat dikombinasikan dengan berbagai lapisan lain atau disusun secara bertingkat, Inception module memungkinkan fleksibilitas dalam eksperimen dengan kedalaman, kompleksitas, dan jumlah parameter. Ini memungkinkan desain arsitektur yang sesuai untuk tugas tertentu dan kebutuhan komputasi yang tersedia.

- Efisiensi Energi pada Perangkat Terbatas

Karena efisiensi komputasinya, Inception module sering kali digunakan pada perangkat dengan sumber daya terbatas (misalnya perangkat edge atau mobile), yang tidak memiliki kemampuan komputasi setara dengan server atau GPU yang kuat.

TANTANGAN DALAM INCEPTION MODULE

Tidak terlepas dari kekurangan, adapun tantangan dalam pengembangan modul ini

- Kompleksitas yang Meningkat

Arsitektur dari Inception Module lebih kompleks dibandingkan dengan lapisan tradisional, yang bisa membuatnya lebih sulit untuk dirancang dan dilatih.

- Penyesuaian Hyperparameter

Modul ini memperkenalkan hyperparameter tambahan, seperti jumlah dan ukuran filter, yang memerlukan penyesuaian yang cermat untuk mencapai performa yang optimal.

- Intensitas Sumber Daya

Meskipun dirancang untuk efisiensi, Inception Module masih bisa menghabiskan banyak sumber daya karena jumlah operasi yang besar dan proses penggabungan output.

THANK YOU